



# **INSTITUTO TECNOLÓGICO DE HERMOSILLO**

## **Mineria de Datos**

### ***Proyecto final***

#### **Equipo:**

**Jimenez Varela Diego**

**Meneses Arvizu Javier**

#### **Docente:**

**Gandarilla Gelacio Germán**

**Hermosillo, Sonora**

**27 de Mayo del 2026**

# 1. Introducción y contexto del problema

La diabetes es una de las enfermedades crónicas con mayor impacto en la salud pública debido a su prevalencia, complicaciones y costo asociado al tratamiento. En México, los datos de la Encuesta Nacional de Salud y Nutrición (ENSANUT) muestran que una proporción importante de la población adulta vive con esta enfermedad, mientras que la detección tardía dificulta su prevención y control.

En este contexto, la minería de datos permite analizar grandes volúmenes de información para identificar patrones relacionados con la presencia de diabetes. A partir de variables clínicas, demográficas y de estilo de vida, es posible construir modelos capaces de apoyar la detección de personas con mayor riesgo.

El presente proyecto tiene como objetivo desarrollar y evaluar distintos modelos de clasificación (KNN, Arbol de decisión, XGBoost) utilizando datos de la ENSANUT Continua 2024. Para ello, se trabajó con un conjunto de datos principales y otro enriquecido con información adicional (menos registros) proveniente de distintos cuestionarios.

## 1.1 Pregunta de investigación

¿Es posible clasificar a una persona adulta como “con diabetes” o “sin diabetes” a partir de variables demográficas, biométricas, antecedentes familiares y hábitos de vida obtenidos de la ENSANUT?

Además, ¿cuáles son las variables más determinantes para realizar dicha clasificación? y ¿cuáles son los perfiles con mayor riesgo?

## 1.2 Objetivos

Para poder contestar a la pregunta de investigación, se tienen los siguiente objetivos:

- Preparar adecuadamente un conjunto de datos real.

- Implementar y comparar diferentes modelos.
- Aplicar técnicas de manejo del desbalance de clases adecuadas al problema.
- Evaluar los modelos con métricas apropiadas y bajo distintos umbrales de decisión.

## **2. Descripción del dataset**

Los datos provienen de la Encuesta Nacional de Salud y Nutrición (ENSANUT) Continua 2024. Es una fuente pública, de cobertura nacional, utilizada para el estudio de la salud de la población mexicana.

### **2.1 Módulos utilizados e integración**

De los archivos disponibles se seleccionaron dos encuestas por su relevancia para el problema: el cuestionario de adultos (variable objetivo y mayoría de factores de riesgo) y el de antropometría (mediciones físicas). Los dos se integraron mediante el identificador único de persona (FOLIO\_INT), presente en ambos archivos, usando una unión interna.

El conjunto integrado quedó con 9,945 registros (personas adultas). Además, se construyó un dataset enriquecido que incorpora los módulos de actividad física y sangre (hemoglobina y micronutrientes), este conjunto tiene 2,733 registros.

### **2.2 Variable objetivo**

La variable objetivo (diabetes) se construyó a partir de la pregunta del cuestionario sobre si un médico le ha diagnosticado diabetes a la persona. Se codificó como una variable binaria (1 = diabetes y 0 = no), y los casos de diabetes gestacional se descartaron por ser una entidad clínica distinta. La distribución resultante es de 8,610 personas sin diabetes (86.6 %) y 1,335 con diabetes (13.4 %). La distribución con el enriquecido tiene un porcentaje menor, con solo 11.4 %.

## **2.3 Variables predictoras**

Tras la selección se conservan alrededor de veinte variables predictoras, agrupables en seis bloques:

- Demográficas: edad, sexo.
- Biométricas: índice de masa corporal, peso, talla, circunferencia de cintura, presión arterial sistólica y diastólica.
- Antecedentes familiares: padre, madre y hermano(a) con diabetes y con hipertensión.
- Comorbilidades: hipertensión, colesterol y triglicéridos altos, enfermedad renal.
- Salud mental: índice de síntomas depresivos derivado de siete reactivos.
- Hábitos y otros: tabaquismo (actual y pasado), consumo de alcohol, cambio reciente de peso.

El dataset enriquecido añade nueve variables clínicas: hemoglobina, ferritina, vitamina B12, vitamina D, horas de sueño, días por semana de actividad vigorosa, moderada y caminata, y horas sentado.

## **2.4 Consideración sobre la fuga de datos**

El cuestionario contiene numerosas variables que son consecuencia de tener diabetes y que solo existen para las personas ya diagnosticadas. Por esta razón se excluyeron de los dos dataset, ya que incluirlas causaría una fuga de datos y produciría un modelo con un desempeño falso.

# **3. Metodología**

## **3.1 Proceso**

El proyecto se organizó en cinco etapas principales: análisis y exploración de datos (EDA), preparación de los datos, modelado y evaluación.

### **3.2 Preparación de los datos**

La preparación de los datos incluyó varias decisiones importantes. Para empezar, las preguntas categóricas de la ENSANUT codifican la no respuesta mediante los valores 8 (“No sabe”) y 9 (“No responde”), por lo que estos se transformaron en valores faltantes para evitar que fueran interpretados como categorías válidas. Además, algunas variables biométricas contenían valores fuera de rangos clínicamente posibles, probablemente debido a errores de captura. Para esos casos, los valores fueron anulados en lugar de eliminar el registro completo para conservar el resto de la información de cada persona.

Para algunas variables fue necesario hacer ingeniería de características. Las variables binarias se codificaron a formato 0/1, se construyó un índice de síntomas depresivos a partir de la suma de estos y se generaron variables con el número de familiares directos con diabetes e hipertensión.

Finalmente, los valores faltantes se imputaron utilizando la mediana calculada únicamente sobre el conjunto de entrenamiento, evitando así fuga de información hacia el modelo. Además, la mediana se utilizó para reducir el efecto de valores extremos.

### **3.3 División train/val/test**

El conjunto se dividió en tres subconjuntos: entrenamiento (60 %), validación (20 %) y prueba (20 %), con muestreo estratificado para preservar la proporción de clases y con semilla fija (42) para garantizar la reproducibilidad. El conjunto de validación se usa para el ajuste de hiperparámetros, la elección de la mejor variante de SMOTE y la selección del umbral de decisión. El conjunto de pruebas se utilizó solo para la evaluación final.

### **3.4 Manejo del desbalance: variantes de SMOTE**

Debido a que las personas con diabetes representan solo el 13.4/11.4 % de los datos, se aplicaron técnicas de balanceo basadas en SMOTE. Se compararon seis

variantes: SMOTE, ADASYN, BorderlineSMOTE, SMOTE-NC, SMOTE-ENN y SMOTE-Tomek.

La selección del método se realizó comparando el desempeño en AUC de cada variante utilizando el mismo modelo base. En el conjunto principal, la técnica con mejor resultado fue SMOTE-ENN, que combina sobremuestreo con limpieza de la frontera mediante Edited Nearest Neighbors. Por otro lado, en el conjunto enriquecido, el mejor desempeño se obtuvo con SMOTE estándar.

### **3.5 Modelos implementados**

Se implementaron cuatro modelos supervisados:

- Árbol de decisión simple (línea base, sin balanceo ni ajuste de hiperparámetros).
- Árbol de decisión ajustado con SMOTE-ENN y `GridSearchCV` por AUC.
- K-Nearest Neighbors con SMOTE-ENN, escalado y `GridSearchCV` por AUC.
- XGBoost (gradient boosting) con SMOTE-ENN y `GridSearchCV` por AUC.

También se aplicó K-Means como modelo no supervisado para descubrir perfiles naturales de riesgo en la población. K-Means se ejecutó sobre ambos datasets (principal y enriquecido) como análisis exploratorio inicial.

### **3.6 Métricas de evaluación y ajuste del umbral**

Los modelos se evaluaron sobre el conjunto de prueba con: matriz de confusión, precisión, recall, F1-score y AUC. El accuracy se reporta pero no se usa como criterio principal, ya que con clases desbalanceadas resulta engañoso.

La decisión del GridSearchCV se optimiza con AUC, porque mide la capacidad del modelo para separar las clases independiente del umbral. Por otro lado, el ajuste del umbral de decisión se realiza con F2-score sobre el conjunto de validación, el pondera el recall cuatro veces sobre la precisión. Se eligió este enfoque porque un falso negativo tiene un mayor impacto que un falso positivo. Sin embargo, tampoco es

conveniente maximizar únicamente el recall, ya que esto podría generar una cantidad excesiva de falsos positivos.

La evaluación final se reporta utilizando dos umbrales: 0.50 (valor por defecto) y el umbral óptimo obtenido mediante F2 para cada dataset. Esto permite comparar cómo cambia el comportamiento del modelo en términos de precisión y recall según el umbral utilizado.


## 4. Resultados y análisis

### 4.1 Análisis exploratorio del dataset

La Figura 1 muestra la distribución de la variable objetivo y el desbalance de clases, donde solo cerca del 13 % tiene diabetes diagnosticada. Por esta razón es que se tuvo que utilizar técnicas como SMOTE.

**Figura 1**


*Distribución de la variable objetivo.*



La Figura 2 compara la distribución de la edad entre ambos grupos. La diabetes se concentra claramente en edades mayores, el grupo positivo está desplazado hacia la derecha, lo que anticipa que la edad será una variable predictora central.

**Figura 2.**


*Distribución de la edad según diagnóstico de diabetes.*



La Figura 3 compara el índice de masa corporal y la circunferencia de cintura entre ambos grupos. En las personas con diabetes ambas medidas son mayores, lo que coincide con la obesidad, el cual es un factor de riesgo.

**Figura 3.**

*Índice de masa corporal y cintura según el diagnóstico.*




La Figura 4 muestra el porcentaje de personas con diabetes según tengan o no antecedentes familiares de la enfermedad. La proporción es notablemente mayor en el grupo con antecedentes, lo que confirma el componente hereditario de la enfermedad.

**Figura 4.**

*Porcentaje de personas con diabetes según antecedentes familiares.*






Finalmente, la Figura 5 presenta la matriz de correlación de las variables numéricas. La edad y la presión sistólica muestran la correlación positiva más alta con la variable objetivo.

**Figura 5.**

*Matriz de correlación de las variables numéricas.*




## 4.2 K-Means exploratorio

Antes del modelado supervisado se aplicó K-Means sobre el dataset principal para descubrir si existen perfiles naturales de mayor o menor riesgo. La Figura 6 muestra el método del codo y el coeficiente de silueta, que orientan la elección del número de grupos.

**Figura 6.**

*Método del codo y coeficiente de silueta para elegir  $k$  (dataset principal).*




Con  $k=5$  elegido por silueta, los siete clusters muestran tasas de diabetes claramente diferentes. Los grupos de mayor riesgo concentran personas de mayor edad y con valores elevados de IMC y cintura, alcanzando hasta el 27% de prevalencia. El grupo de menor riesgo está formado por personas jóvenes con biometría normal. Esto confirma de manera independiente que existen perfiles poblacionales claramente diferenciados en cuanto al riesgo de diabetes.

### 4.3 Comparación de variantes de SMOTE

Para tratar el desbalance se compararon las seis variantes de SMOTE disponibles, entrenando en cada caso un árbol de decisión con parámetros por defecto y midiendo el desempeño sobre el conjunto de validación. La Figura 7 resume la comparación.

**Figura 7.**

*Comparación de las seis variantes de SMOTE (validación).*




SMOTE-ENN resultó ser la variante con mejor AUC en validación del principal. Esta técnica genera ejemplos sintéticos con SMOTE y después elimina los puntos cuya clase no concuerda con la de sus vecinos mediante Edited Nearest Neighbors. Esta limpieza reduce el ruido y mejora la capacidad de discriminación.

#### 4.4 Comparativa de modelos supervisados

Sobre el conjunto de prueba se evaluaron cuatro modelos: árbol simple, árbol ajustado, KNN y XGBoost. La Figura 8 y la Tabla 1 siguiente resumen el desempeño.

**Figura 8**

*Comparación de los cuatro modelos supervisados (test, umbral 0.50).*



**Tabla 1**

*Tabla de comparación de parámetros de los modelos supervisados*

| Modelo              | Precisión | Recall | F1    | F2    | AUC   |
|---------------------|-----------|--------|-------|-------|-------|
| 1. Árbol simple     | 0.274     | 0.330  | 0.299 | 0.317 | 0.597 |
| 2. Árbol ajustado   | 0.293     | 0.685  | 0.410 | 0.540 | 0.785 |
| 3. KNN ajustado     | 0.230     | 0.876  | 0.365 | 0.561 | 0.790 |
| 4. XGBoost ajustado | 0.332     | 0.697  | 0.449 | 0.571 | 0.817 |

El modelo seleccionado fue XGBoost, ya que obtuvo el mejor desempeño general entre los modelos evaluados. Presentó la mayor AUC (0.817), así como los mejores valores de F1 (0.449) y precisión (0.332). Además, a diferencia de un árbol de decisión individual, XGBoost combina múltiples árboles, lo que le permite generar probabilidades más continuas y facilita un ajuste más preciso del umbral de clasificación.


Los resultados también muestran la importancia del manejo del desbalance de clases. El árbol de decisión sin balanceo obtuvo un AUC de 0.589, apenas por encima del azar. Por otro lado, KNN alcanzó el recall más alto (0.876), pero con una precisión considerablemente baja (0.230), lo que reduce su utilidad práctica. Finalmente, el árbol ajustado presentó un desempeño decente pero conserva la ventaja de ser interpretable.

#### **4.5 Importancia de atributos y regla de decisión**

La Figura 9 muestra la importancia de los atributos del XGBoost, que combina cientos de árboles internos. La edad y el número de familiares con diabetes son los que presentan mayor importancia. Esto coincide con el análisis exploratorio que se había hecho.

**Figura 9.**

### *Importancia de atributos del modelo XGBoost.*




Una de las ventajas del árbol de decisión es que sus reglas pueden leerse directamente. A partir del árbol ajustado se extrae una regla de tipo IF-THEN como si la edad supera cierto umbral, existe antecedente familiar de diabetes y el índice de masa corporal es elevado, entonces la persona se clasifica con riesgo de diabetes.

#### **4.6 Ajuste del umbral de decisión**

Sobre el modelo final (XGBoost) se calculó el umbral que maximiza el F2-score en el conjunto de validación. La Figura 10 muestra cómo varían la precisión, el recall y el F2-score con el umbral. Las líneas verticales indican el umbral por defecto 0.50 y el F2 óptimo encontrado.

**Figura 10.**

*Métricas según el umbral de decisión (validación, dataset principal).*




El umbral F2 óptimo en el dataset principal resultó en aproximadamente 0.39, ligeramente por debajo del 0.50 por defecto. Este corte aumenta el recall a costa de algo de precisión, alineado con el costo clínico del problema.

#### 4.7 Evaluación final sobre el conjunto de prueba (principal)

La Figura 11 muestra las matrices de confusión de cada umbral y la curva AUC. En las tablas 2 y 3 se puede observar los resultados por cada umbral.

**Figura 11.**

*Matrices de confusión y curva ROC del modelo XGBoost sobre prueba (principal).*



**Tabla 2.**

*Tabla de precisión, recall y F1 del modelo XGBoost con umbral 0.5*

| Umbral 0.5  | Precisión | Recall | F1   |
|-------------|-----------|--------|------|
| No diabetes | 0.94      | 0.78   | 0.86 |
| Diabetes    | 0.33      | 0.70   | 0.45 |

**Tabla 3.**

*Tabla de precisión, recall y F1 del modelo XGBoost con umbral 0.39*

| Umbral 0.39 | Precisión | Recall | F1   |
|-------------|-----------|--------|------|
| No diabetes | 0.95      | 0.71   | 0.81 |
| Diabetes    | 0.29      | 0.76   | 0.42 |

En el contexto del proyecto, el umbral de 0.39 sería el más adecuado, ya que permitió aumentar el recall. Esto logró identificar una mayor cantidad de casos positivos de diabetes aunque esto produjo una disminución en la precisión.

#### 4.8 Análisis con el dataset enriquecido


Como análisis complementario se construyó un segundo conjunto de datos que añade variables de actividad física y de sangre.

##### 4.8.1 K-Means exploratorio en el enriquecido

La Figura 12 muestra el método del codo y el coeficiente de silueta para el dataset enriquecido.

**Figura 12.**

*Método del codo y coeficiente de silueta para elegir k (enriquecido).*



Con  $k=7$  elegido por silueta, se observan clusters con tasas de diabetes claramente diferenciadas. Los grupos de mayor riesgo concentran personas mayores con IMC elevado, y se aprecia que la hemoglobina aporta una dimensión adicional de separación que no estaba en el dataset principal. Esta nueva variable ayudó de manera significativa, ya que se tiene un grupo con una tasa de diabetes del casi 36 %.

#### 4.8.2 Selección del SMOTE para el enriquecido

Se probaron las tres mejores variantes de SMOTE del dataset principal (SMOTE-ENN, SMOTE y SMOTE-Tomek), cada una con un XGBoost (Con GridsearchCV) sobre el dataset enriquecido. El SMOTE normal fue el que obtuvo un mayor AUC, aunque por poca diferencia. La razón es que en el enriquecido los puntos minoritarios son menos densos (solo 2,733 registros) y la limpieza adicional de SMOTE-ENN elimina demasiados ejemplos sintéticos, dejando muy poca minoría efectiva para entrenar. Con SMOTE normal no hay limpieza posterior, así que el conjunto balanceado conserva más información y XGBoost aprovecha mejor las variables clínicas adicionales.


#### 4.8.3 Ajuste del umbral y evaluación final

Con XGBoost entrenado sobre el dataset enriquecido se calculó el umbral que maximiza el F2-score en validación. La Figura 13 muestra las métricas según el umbral, donde las líneas verticales indican el umbral por defecto 0.50 y el F2 óptimo encontrado.



Figura 13.

Métricas según el umbral de decisión (validación, dataset enriquecido).



El umbral F2 óptimo del enriquecido resultó en aproximadamente 0.21, mucho menor al del principal (0.39).

La Figura 14 presenta las matrices de confusión con los dos umbrales y la curva AUC final sobre el conjunto de prueba enriquecido. En la Tabla 4 y 5 se pueden ver los resultados por cada umbral.

Figura 14.

Matrices de confusión y curva ROC del XGBoost sobre prueba (enriquecido).




Tabla 4.

Tabla de precisión, recall y F1 del modelo XGBoost con prueba enriquecida con umbral 0.50

| Umbral 0.50 | Precisión | Recall | F1   |
|-------------|-----------|--------|------|
| No diabetes | 0.94      | 0.94   | 0.94 |
| Diabetes    | 0.50      | 0.50   | 0.50 |

**Tabla 5.**

*Tabla de precisión, recall y F1 del modelo XGBoost con prueba enriquecida con umbral 0.21*

| Umbral 0.21 | Precisión | Recall | F1   |
|-------------|-----------|--------|------|
| No diabetes | 0.97      | 0.74   | 0.84 |
| Diabetes    | 0.28      | 0.82   | 0.42 |

El dataset enriquecido produce dos resultados notables. Con el umbral por defecto (0.50), el modelo obtiene un balance excepcional (precisión y recall con 0.50). Este es el mejor balance entre recall y precisión de todo el proyecto. Con el umbral F2 (0.21), el recall sube a 0.82 al costo de bajar la precisión a 0.28. Las variables clínicas adicionales en particular la hemoglobina, que K-Means destacaba aportan información que el modelo aprovecha.

#### 4.9 Comparativa global

La tabla siguiente resume los resultados de los modelos comparables sobre prueba:

**Tabla 5.**

*Tabla de comparación de accuracy, precisión, recall, F1-score y AUC de todos los modelos, con prueba no enriquecida y prueba enriquecida.*

| Configuración | Accurac<br>y | Precisió<br>n | Recall | F1 | AUC |
|---------------|--------------|---------------|--------|----|-----|
|---------------|--------------|---------------|--------|----|-----|

|                                        |       |       |       |       |       |
|----------------------------------------|-------|-------|-------|-------|-------|
| Árbol simple (principal)               | 0.793 | 0.274 | 0.330 | 0.299 | 0.597 |
| Árbol ajustado + SMOTE-ENN (principal) | 0.736 | 0.293 | 0.685 | 0.410 | 0.785 |
| KNN + SMOTE-ENN (principal)            | 0.590 | 0.230 | 0.876 | 0.365 | 0.790 |
| XGBoost + SMOTE-ENN (principal, 0.50)  | 0.771 | 0.332 | 0.697 | 0.449 | 0.817 |
| XGBoost + SMOTE-ENN (principal, F2)    | 0.715 | 0.288 | 0.760 | 0.418 | 0.817 |
| XGBoost + SMOTE (enriquecido, 0.50)    | 0.887 | 0.500 | 0.500 | 0.500 | 0.872 |
| XGBoost + SMOTE (enriquecido, F2)      | 0.746 | 0.285 | 0.823 | 0.423 | 0.872 |

Ya con todos los modelos evaluados, el modelo recomendado es XGBoost utilizando el dataset enriquecido con SMOTE y un umbral de clasificación de 0.21 (F2). La elección se debe a que presentó el mejor balance entre las métricas evaluadas, manteniendo un recall superior a 0.80.

El objetivo principal era priorizar el recall sin que la precisión fuera excesivamente baja. Aunque la precisión aún es baja, este modelo obtuvo la mejor precisión entre aquellos con recall alto. Además, presentó el segundo mejor recall y el mejor AUC entre los modelos evaluados.

## 5. Discusión crítica y limitaciones

En el proyecto hubo varias limitaciones. Una limitación del proyecto es que la variable objetivo corresponde a un diagnóstico autorreportado, por lo que las personas

con diabetes no diagnosticada son consideradas como negativas. Esto dificulta mas al modelo poder clasificar cuando tiene diabetes o no.

Otra limitación importante es la presencia de valores faltantes en algunas variables, especialmente en la presión arterial. Aunque la imputación mediante la mediana es una solución razonable, introduce cierto grado de incertidumbre.

Otra limitación es que muchas variables médicas no cuentan con mediciones numéricas detalladas. Variables como colesterol, triglicéridos y otras similares podrían aportar información más útil si se incluyeran valores directos, por ejemplo en mg/dL. Además, no fue posible incorporar la encuesta de alimentación debido a la complejidad de su procesamiento. Este conjunto contenía más de 600 000 registros y almacenaba información por alimento consumido por cada persona, en lugar de agruparla por categorías de alimentos.

En cuanto al desempeño, la precisión de la clase positiva sigue siendo relativamente baja, lo que significa una cantidad alta de falsos positivos. Sin embargo, esto resulta aceptable en este contexto, donde un falso positivo solo serían más pruebas de confirmación adicionales.

En un trabajo futuro, se buscaría utilizar datos con mediciones directas y diagnósticos confirmados para mejorar la calidad de la variable objetivo y de las variables predictoras. Además, se buscarían modelos más avanzados, ya que XGBoost presentó un desempeño mejor en comparación con modelos como KNN y Árbol de Decisión.

## **6. Conclusiones**

En este proyecto se desarrollaron modelos para clasificar el riesgo de diabetes en personas adultas a partir de información de la ENSANUT 2024. A lo largo del proceso se compararon distintos modelos, técnicas de balanceo y umbrales de decisión. Esto fue con el fin de encontrar una solución para el problema del desbalanceo y la importancia de los falsos negativos.

Los resultados mostraron que XGBoost sobre el dataset enriquecido con SMOTE fue el mejor modelo global, con un AUC de 0.872. Con el umbral F2 de 0.21, logró alcanzar un recall de 0.82, priorizando la detección de casos positivos. En el dataset principal, XGBoost también obtuvo el mejor desempeño entre los modelos comparados, aunque con métricas inferiores a las del conjunto enriquecido.

El análisis exploratorio pudo confirmar que variables como la edad, el IMC, la cintura, los antecedentes familiares y, en el dataset enriquecido, la hemoglobina, son de las más determinantes para la clasificación. Además, K-Means permitió identificar perfiles poblacionales con distinto nivel de riesgo.

En conclusión, el proyecto se podría considerar que cumple su objetivo y muestra que es posible clasificar si tiene diabetes o no, con un desempeño sólido. Pero se podría mejorar considerando las limitaciones del dato autorreportado, los valores faltantes y añadir mejores variables.

## 7. Referencias

Instituto Nacional de Estadística y Geografía & Secretaría de Salud. (2024). Encuesta Nacional de Salud y Nutrición (ENSANUT) 2024. INEGI. Recuperado de <https://ensanut.insp.mx/> (consultado el 19 de mayo de 2026).

GeeksforGeeks. (s.f.). K-means clustering – Introduction. GeeksforGeeks. Recuperado de <https://www.geeksforgeeks.org/machine-learning/k-means-clustering-introduction/> (consultado el 24 de mayo de 2026).

Scikit-learn developers. (s.f.). StratifiedKFold. Scikit-learn. Recuperado de [https://scikit-learn.org/stable/modules/generated/sklearn.model\\_selection.StratifiedKFold.html](https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedKFold.html) (consultado el 22 de mayo de 2026).

GeeksforGeeks. (s.f.). Building and implementing decision tree classifiers with Scikit-learn: A comprehensive guide. GeeksforGeeks. Recuperado de <https://www.geeksforgeeks.org/machine-learning/building-and-implementing-decision-tree-classifiers-with-scikit-learn-a-comprehensive-guide/> (consultado el 22 de mayo de 2026).

GeeksforGeeks. (s.f.). GradientBoosting vs AdaBoost vs XGBoost vs CatBoost vs LightGBM. GeeksforGeeks. Recuperado de <https://www.geeksforgeeks.org/machine-learning/gradientboosting-vs-adaboost-vs-xgboost-vs-catboost-vs-lightgbm/> (consultado el 25 de mayo de 2026).

Tilii7. (s.f.). Hyperparameter grid search with XGBoost. Kaggle. Recuperado de <https://www.kaggle.com/code/tilii7/hyperparameter-grid-search-with-xgboost> (consultado el 25 de mayo de 2026).

GeeksforGeeks. (s.f.). How to generate feature importance plots from Scikit-learn. GeeksforGeeks. Recuperado de <https://www.geeksforgeeks.org/machine-learning/how-to-generate-feature-importance-plots-from-scikit-learn/> (consultado el 24 de mayo de 2026).

Scikit-learn developers. (s.f.). export\_text. Scikit-learn. Recuperado de [https://scikit-learn.org/stable/modules/generated/sklearn.tree.export\\_text.html](https://scikit-learn.org/stable/modules/generated/sklearn.tree.export_text.html) (consultado el 22 de mayo de 2026).

## 8. Anexos: fragmentos de código relevante

### Anexo A. Construcción de la variable objetivo

```
df['diabetes'] = df['a0301'].map({1: 1, 3: 0})
```

```
df = df[df['diabetes'].notna()].copy()
```

## **Anexo B. Comparación de las 6 variantes de SMOTE**

```
VARIANTES_SMOTE = {  
    'SMOTE'      : SMOTE(random_state=SEMILLA),  
    'ADASYN'     : ADASYN(random_state=SEMILLA),  
    'BorderlineSMOTE': BorderlineSMOTE(random_state=SEMILLA),  
    'SMOTE-NC'   : SMOTENC(categorical_features=CAT_IDX,  
random_state=SEMILLA),  
    'SMOTE-ENN'  : SMOTEENN(random_state=SEMILLA),  
    'SMOTE-Tomek' : SMOTETomek(random_state=SEMILLA),  
}
```

```
resultados_smote = {}  
for nombre, variante in VARIANTES_SMOTE.items():  
    X_bal, y_bal = variante.fit_resample(X_train_i, y_train)  
    modelo = DecisionTreeClassifier(random_state=SEMILLA)  
    modelo.fit(X_bal, y_bal)
```

## **Anexo C. Pipeline XGBoost con SMOTE-ENN y GridSearch**

```
pipe_xgb = ImbPipeline([  
    ('smote', SMOTEENN(random_state=SEMILLA)),  
    ('modelo', XGBClassifier(random_state=SEMILLA, eval_metric='logloss',  
                             verbosity=0)),  
)  
malla_xgb = {  
    'modelo__n_estimators': [100, 200],  
    'modelo__max_depth':    [3, 4, 5],  
    'modelo__learning_rate': [0.05, 0.1],  
}  
busq_xgb = GridSearchCV(pipe_xgb, malla_xgb, scoring='roc_auc',  
                        cv=StratifiedKFold(5, shuffle=True, random_state=SEMILLA), n_jobs=-1)
```

```
busq_xgb.fit(X_train_i, y_train)
```

#### **Anexo D. Ajuste del umbral F2**

```
prec_e, rec_e, umbrales_e = precision_recall_curve(ye_val, proba_e_val_final)
```

```
f2_e = (5 * prec_e * rec_e) / (4 * prec_e + rec_e + 1e-9)
```

```
UMBRAL_F2_ENR = float(umbrales_e[int(np.argmax(f2_e[:-1]))])
```