



INSTITUTO TECNOLÓGICO DE HERMOSILLO

ING. EN SISTEMAS COMPUTACIONALES

MINERÍA DE DATOS

Propuesta de Proyecto

DOCENTE:

M.C. GERMAN GANDARILLA GELACIO

EQUIPO 6:

DIEGO JIMENEZ VARELA

MENESES ARVIZU JAVIER

Hermosillo, Sonora a 11 de mayo de 2026

1. Descripción del problema

La diabetes es una de las enfermedades crónicas más comunes en México y representa un importante problema de salud pública. Según la INSP, el 18.4% de las personas adultas viven con diabetes.

Uno de los principales problemas es que muchas personas son diagnosticadas cuando ya presentan complicaciones graves. Detectar a tiempo a las personas con mayor riesgo permitiría aplicar medidas preventivas para mejorar su calidad de vida y reducir los costos en el sistema de salud.

Este proyecto busca abordar este problema mediante técnicas de minería de datos. A partir de datos biométricos y hábitos de vida de adultos mexicanos, se pretende construir modelos capaces de identificar automáticamente a las personas con alto riesgo de padecer diabetes.

2. Pregunta de investigación

¿Es posible clasificar a una persona adulta como “con diabetes” o “sin diabetes” a partir de variables demográficas, biométricas, antecedentes familiares y hábitos de vida de la ENSANUT?

¿Qué variables son las más determinantes para esa clasificación?

3. Datos a usar

Se utilizará la Encuesta Nacional de Salud y Nutrición (ENSANUT) 2024, elaborada por el INEGI y la Secretaría de Salud. Es una fuente pública, real y de cobertura nacional.

Tipo de datos	Respuestas de cuestionario y mediciones clínicas de personas adultas
Registros	Aproximadamente 12,900 adultos en el cuestionario. Al momento de juntarlo con las otras encuestas bajara (Principal: 9,000 y Enriquecido: 3,000).
Variables	Más de 800 en el archivo original; tras la selección, alrededor de 23 variables predictoras (edad, sexo, IMC, cintura, presión arterial, antecedentes familiares, hipertensión, hábitos). Con el enriquecido sube hasta 32.
Formato	Archivos .dta (Stata) y .csv, acompañados de catálogos .xlsx que describen cada variable

4. Métodos a aplicar

Supervisado: Árbol de decisión, KNN y XGBoost

No supervisado: K-Means

5. División del trabajo

Diego Jimenez Varela: Preprocesamiento de datos: descarga y exploración inicial del dataset ENSANUT 2024, limpieza de valores faltantes y duplicados, análisis de outliers, normalización y codificación de variables categóricas, EDA.

Javier Meneses Arvizu: Implementación y evaluación de modelos: entrenamiento de KNN y K-Means sobre el dataset preprocesado, ajuste de hiperparámetros, cálculo de métricas de evaluación (matriz de confusión, F1-score, curva ROC) y tabla comparativa de modelos.